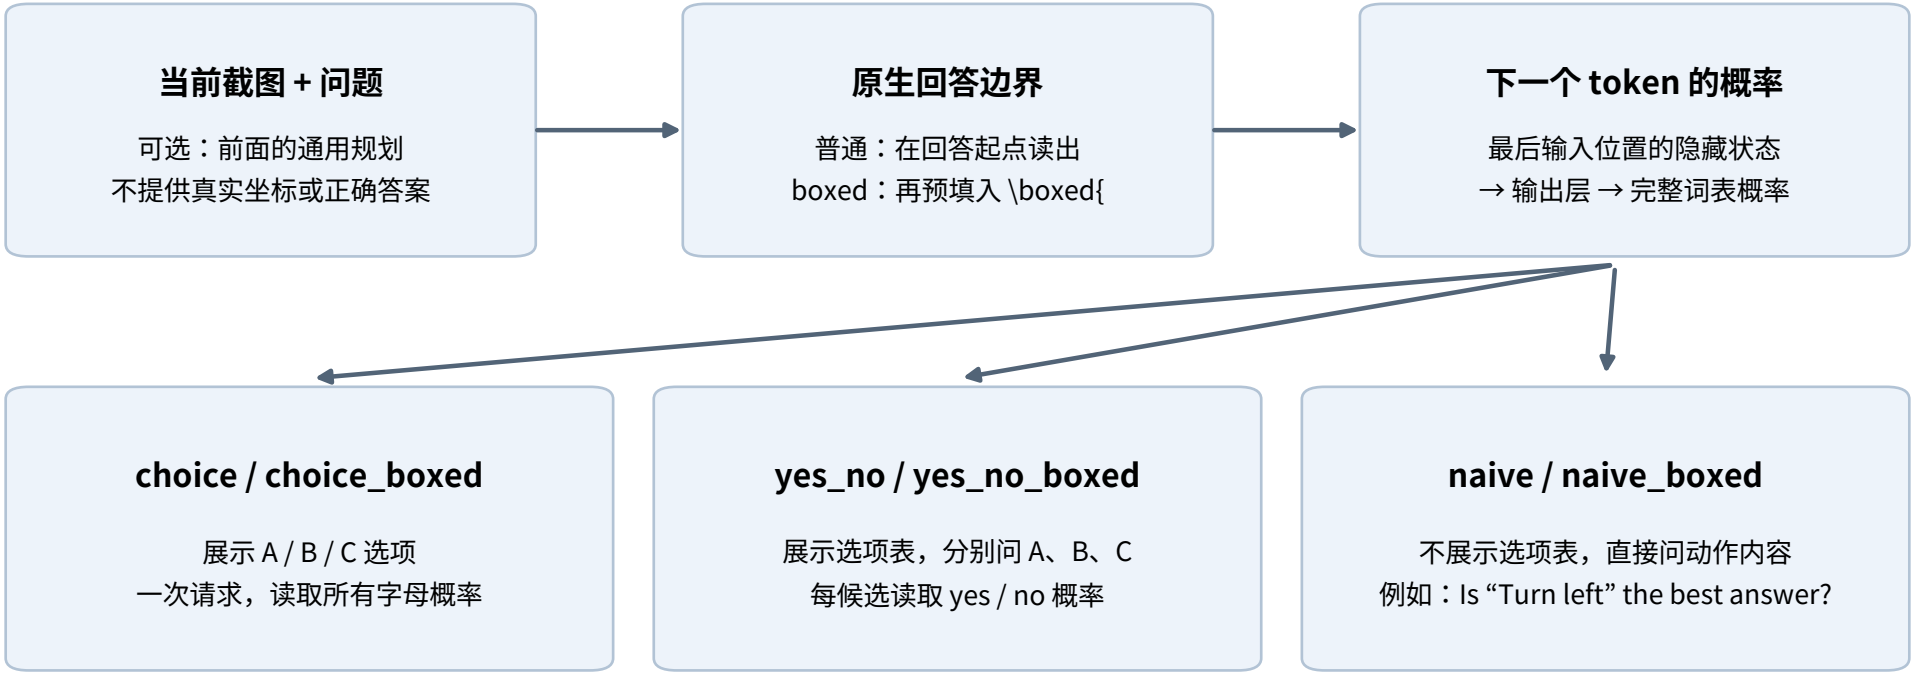
原理：我们测的是“下一步准备回答什么”



先检查：模型是否愿意输出规定的答案？ → 再比较候选分数 → 最后检查选得对不对

boxed 是输入前缀，不等待模型自己生成；图示省略不同模型的原生模板细节。