四条件：比较保留哪些规划上下文

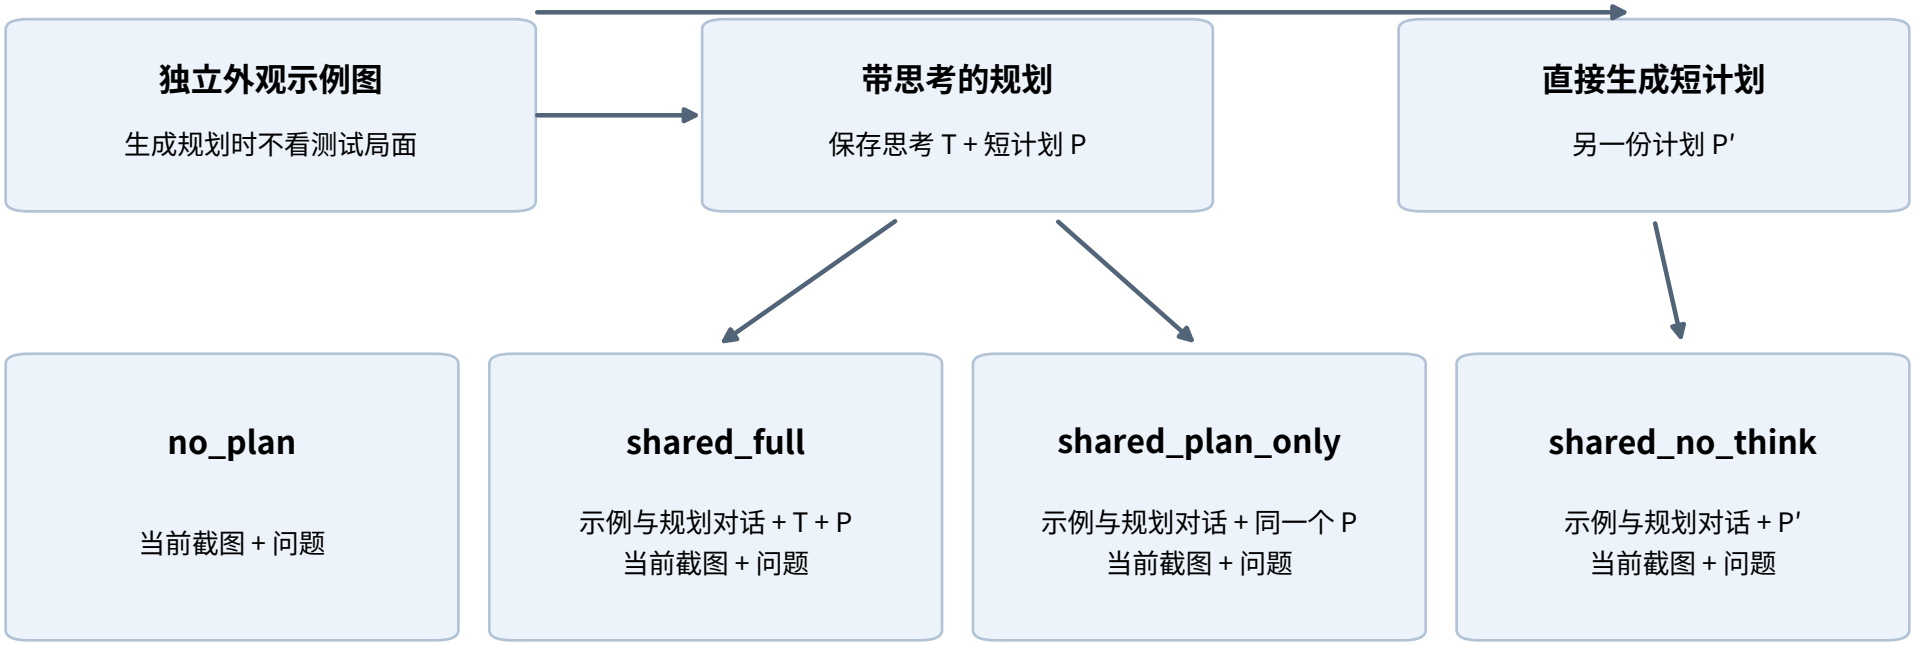

每个模型、每个 seed：两份规划；perception 与 readout 共用，六种评分方法也共用。